

**MBA
USP
ESALQ**

**Impacto das escolas no desempenho
ENEM: comparação de modelos
preditivos com dados educacionais e
socioeconômicos**

Breno Garcia Ferraz
Diego Pedroso dos Santos

O que importa
mais para um
**bom desempenho
no ENEM?**





Scott

ENSINO SUPERIOR

- Fase crucial para a vida profissional
- Formação de especialistas
- Etapa que a desigualdade fica evidente



Bourdieu

Becker

Passeron

Capital Humano

- Educação
- Produtividade/Renda
- Economia

Capital Cultural

- **Desigualdade** na educação
- Origens sociais **distintas**
- Favorece a cultura **alinhada** a escola

Ciclo: baixa renda e baixa escolarização

Ascensão Social: ruptura do ciclo



Responsabilidade do Estado

- Educação
- Coleta de indicadores
- Pesquisas

Direcionar o Investimento Público

Promover acesso igualitário à educação



Estudos Anteriores

No que focaram?

- Dados exclusivos do ENEM
- Poucas variáveis
- Público x Privado
- Sem aprofundamento nas escolas

Contribuição

- Variáveis importantes
- Estratégias de modelagem
- Métricas obtidas
- Sugestão de enriquecimento (Censo)


OBJETIVO

- Desenvolver um modelo de regressão para notas, com base em dados do ENEM e do Censo Escolar para alunos do terceiro ano do Ensino Médio de todo o Brasil
- Analisar dados Escolares, Socioeconômicos e seus impactos na nota final, incluindo um maior número de variáveis
- Identificar as características das escolas com maior impacto no desempenho dos alunos e sugerir intervenções independente da renda

Estratégia



Metodologia: CRISP-DM (Shearer, 2000)



Abordagem:


- Estruturada
- Iterativa
- Flexível

Ideal para:

- Modelagem
- Múltiplas fontes de dados


Bases de dados

Dados públicos do INEP



Microdados ENEM 2023

(3.933.955 registros)



Microdados Censo Escolar 2023

(217.625 registros)



Dicionários de dados

Bases de dados



ENEM: Exame Nacional do Ensino Médio

- Criado em 1998 pelo INEP
- Avaliar o desempenho do aluno no 3ºano
- Gerar dados da qualidade do ensino
- Acesso a universidades: ProUni, SISU e FIES
- Dois dias de prova (**cinco disciplinas**)
- **Formulário:** socioeconômicos e escolares



Censo Escolar

- INEP
- Dados de escolas
- Públicas e privadas

Preparação dos Dados: Agrupamento


Problema do código único identificador da escola

- Disponível até 2019 (LGPD) – Simon e Cazella (2017) e Adeodato et al. (2014)
- Agrupamento:
 - o município (5.570)
 - o tipo de escola (privada, municipal, estadual ou federal)
 - o localização (urbana ou rural)
- Estatísticas representativas:
 - o Média (numéricas)
 - o Moda (categóricas)
 - o Porcentagem de verdadeiros (binárias)
- Junção de bases: permite investigar relações entre perfil escolar e desempenho no ENEM

Preparação dos dados: **bases**

Quatro bases para treinamento

- I Base ENEM (40 variáveis)
- II Base dados escolares (73 variáveis)
- III Base dados socioeconômicos (33 variáveis)
- IV Base unificada/completa (106 variáveis)



Escolha dos modelos

- **Problema de regressão:** prever as notas

Atributo	Árvore de Decisão	Random Forest	LightGBM	XGBoost	DNN
Interpretabilidade	Alta	Média	Baixa	Baixa	Muito Baixa
Treinamento	Rápido	Médio	Rápido	Demorado	Demorado
Performance	Baixa	Boa	Excelente	Excelente	Boa
Variáveis Categóricas	Label Encoding	Label Encoding	Nativo	Nativo	One-Hot Encoding Embedding
Sensíveis a Outliers	Sim	Não	Não	Não	Não
Melhor uso	Inicial	Geral	Bases Grandes	Melhor Precisão	Modelo Complexos

CrITÉRIOS

- Literatura
- Características das bases
- Características dos modelos

Escolha das métricas

- **Coeficiente de Determinação (R^2)**
 - Proporção da variabilidade explicada pelo modelo
 - Generalista e boa para comparativos
- **Erro Absoluto Médio (MAE)**
 - Mesma unidade da variável alvo
- **Raiz do Erro Quadrático Médio (RMSE)**
 - Penaliza mais erros maiores

Estratégia de treinamento

Situação

- 106 features
 - Quatro bases
 - Cinco notas
 - Cinco modelos
- } **5x5x4=100 treinos**


Solução

- **Base generalista:** dados ENEM (40) – socioeconômicas e escolares
- **Uma prova:** Ciências Humanas – distribuição normal e pouca assimetria
- **Modelo simples e rápido:** árvore de decisão


Realizado

- 12 treinos
- 80% treino e 20% teste
- Validação cruzada (15% do treino)
- Reprodutibilidade (seed)

Estratégia de treinamento



Estratégia de treinamento




1. Melhor modelo: **LightGBM**

- **Base:** ENEM
- **Disciplina:** Ciências Humanas
- **Modelo:** todos

Métrica	Árvore de Decisão	Random Forest	XGBoost	DNN	LightGBM
MAE	56,5914	55,8744	54,7669	55,1369	54,8517
RMSE	71,5510	70,7671	70,1671	69,9209	69,6036
R2	0,2819	0,2975	0,3094	0,3142	0,3204

Estratégia de treinamento



2. Comparativo por tipo de variável

- **Base:** todas
- **Disciplina:** Ciências Humanas
- **Modelo:** LightGBM


Métrica	Escolares	Socioeconômicos	ENEM	Unificada
MAE	58,7986	56,5698	54,8517	54,8751
RMSE	73,9859	71,5463	69,6036	69,5892
R2	0,2322	0,2820	0,3204	0,3207

- Adicionar dados escolares aos socioeconômicos melhora o modelo, ambos são importantes

Completo x ENEM

- **Variáveis:** 40 x 106 – recurso computacional
- **Previsão exclusiva das notas:** não é necessário dados do Censo
- **Análise atual:** todas as variáveis
- **Limitação da técnica:** agrupamento (grandes e pequenas cidades)

Estratégia de treinamento



3. Treinar um modelo por **disciplina**

- **Base:** unificada
- **Disciplina:** todas
- **Modelo:** LightGBM

Métrica	Ciências Humanas	Ciências da Natureza	Linguagens	Matemática	Redação
MAE	54,8684	51,7956	47,3812	78,7140	134,3155
RMSE	69,5901	64,8283	60,5948	97,2596	180,2670
R²	0,3207	0,3428	0,3233	0,4171	0,3037

Literatura

Pimentel (2021)

- SVR
- Média das notas
 - MAE de 87,23
 - RMSE de 72,83
 - **R² de 0,34**

Stearns et al. (2017)

- XGBoost
- Matemática
 - MAE de 65,9
 - **R² de 0,35**

Santos (2020)

- Diversos modelos
- Matemática
 - MAE $\approx$ 68
 - **R² $\approx$ 0,33**



Santos (2020)

- Diversos modelos
- Redação
 - MAE $\approx$ 145
 - **R² $\approx$ 0,24**

Importância das variáveis: método SHAP



Scott Lundberg



SHAP

- Baseado na teoria dos jogos, o método captura as contribuições e avalia de forma consistente o impacto de cada variável em todas as previsões
- Obtenho a importância de cada variável em cada previsão do modelo

Importância das variáveis: **método SHAP**

2/3 da importância total
para a nota final é devido à variáveis **socioeconômicas**

Agrupando a importância por **tipo de variável**

Variável	Ciências Humanas	Ciências da Natureza	Linguagens	Matemática	Redação
Socioeconômicas	66,1%	64,5%	68,1%	66,6%	66,1%
Escolar	33,9%	35,5%	31,9%	33,4%	33,9%

Comparação com literatura

Impacto na nota final do ENEM

Estudo atual

- ≈66% socioeconômico
- ≈34% escolar
- Brasil
- 73 variáveis escolares
- LightGBM + SHAP

Lobo et al. (2017)

- 84,72% socioeconômico
- 15,28% escolar
- Nordeste
- Escola pública ou privada
- Modelo hierárquico de dois níveis

Ranking importância de variáveis com SHAP

Variável	Mat.
Sexo	1º
Língua Estrangeira	2º
Renda familiar mensal	3º
Qtde. computadores	4º
Cor/raça	5º
Qtde. freezers	6º
Dependência adm.	7º
Cód. município	8º
Faixa etária	9º
Tipo de escola	10º

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.
Sexo	1º	
Língua Estrangeira	2º	1º
Renda familiar mensal	3º	2º
Qtde. computadores	4º	3º
Cor/raça	5º	4º
Qtde. freezers	6º	5º
Dependência adm.	7º	
Cód. município	8º	9º
Faixa etária	9º	7º
Tipo de escola	10º	
UF escola		8º
TV por assinatura		10º
Ocupação pai		6º

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.
Sexo	1º		
Língua Estrangeira	2º	1º	1º
Renda familiar mensal	3º	2º	2º
Qtde. computadores	4º	3º	3º
Cor/raça	5º	4º	4º
Qtde. freezers	6º	5º	5º
Dependência adm.	7º		6º
Cód. município	8º	9º	7º
Faixa etária	9º	7º	8º
Tipo de escola	10º		
Vínculo Sec. Edu			10º
UF escola		8º	
TV por assinatura		10º	9º
Ocupação pai		6º	

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.
Sexo	1º			3º
Língua Estrangeira	2º	1º	1º	1º
Renda familiar mensal	3º	2º	2º	2º
Qtde. computadores	4º	3º	3º	4º
Cor/raça	5º	4º	4º	5º
Qtde. freezers	6º	5º	5º	7º
Dependência adm.	7º		6º	6º
Cód. município	8º	9º	7º	
Faixa etária	9º	7º	8º	
Tipo de escola	10º			10º
Vínculo Sec. Edu			10º	8º
UF escola		8º		
TV por assinatura		10º	9º	9º
Ocupação pai		6º		

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Sexo	1º			3º	1º
Língua Estrangeira	2º	1º	1º	1º	2º
Renda familiar mensal	3º	2º	2º	2º	4º
Qtde. computadores	4º	3º	3º	4º	9º
Cor/raça	5º	4º	4º	5º	10º
Qtde. freezers	6º	5º	5º	7º	
Dependência adm.	7º		6º	6º	7º
Cód. município	8º	9º	7º		6º
Faixa etária	9º	7º	8º		3º
Tipo de escola	10º			10º	
Vínculo Sec. Edu			10º	8º	5º
UF escola		8º			8º
TV por assinatura		10º	9º	9º	
Ocupação pai		6º			

Com 14 variáveis
consigo recuperar as
10 mais importantes
de cada disciplina

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Sexo	1º	14º	43º	3º	1º
Língua Estrangeira	2º	1º	1º	1º	2º
Renda familiar mensal	3º	2º	2º	2º	4º
Qtde. computadores	4º	3º	3º	4º	9º
Cor/raça	5º	4º	4º	5º	10º
Qtde. freezers	6º	5º	5º	7º	12º
Dependência adm.	7º	17º	6º	6º	7º
Cód. município	8º	9º	7º	12º	6º
Faixa etária	9º	7º	8º	18º	3º
Tipo de escola	10º	21º	15º	10º	14º
Vínculo Sec. Edu	13º	11º	10º	8º	5º
UF escola	15º	8º	12º	11º	8º
TV por assinatura	11º	10º	9º	9º	21º
Ocupação pai	12º	6º	11º	16º	13º

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Sexo	1º	14º	43º	3º	1º
Língua Estrangeira	2º	1º	1º	1º	2º
Renda familiar mensal	3º	2º	2º	2º	4º
Qtde. computadores	4º	3º	3º	4º	9º
Cor/raça	5º	4º	4º	5º	10º
Qtde. freezers	6º	5º	5º	7º	12º
Dependência adm.	7º	17º	6º	6º	7º
Cód. município	8º	9º	7º	12º	6º
Faixa etária	9º	7º	8º	18º	3º
Tipo de escola	10º	21º	15º	10º	14º
Vínculo Sec. Edu	13º	11º	10º	8º	5º
UF escola	15º	8º	12º	11º	8º
TV por assinatura	11º	10º	9º	9º	21º
Ocupação pai	12º	6º	11º	16º	13º

Socioeconômicas

- Confirmam padrões de estudos anteriores

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Sexo	1º	14º	43º	3º	1º
Língua Estrangeira	2º	1º	1º	1º	2º
Renda familiar mensal	3º	2º	2º	2º	4º
Qtde. computadores	4º	3º	3º	4º	9º
Cor/raça	5º	4º	4º	5º	10º
Qtde. freezers	6º	5º	5º	7º	12º
Dependência adm.	7º	17º	6º	6º	7º
Cód. município	8º	9º	7º	12º	6º
Faixa etária	9º	7º	8º	18º	3º
Tipo de escola	10º	21º	15º	10º	14º
Vínculo Sec. Edu	13º	11º	10º	8º	5º
UF escola	15º	8º	12º	11º	8º
TV por assinatura	11º	10º	9º	9º	21º
Ocupação pai	12º	6º	11º	16º	13º

Socioeconômicas

- Confirmam padrões de estudos anteriores
- Novas observações
- Superam variáveis tradicionais
 - Quantidade de banheiros
 - Quantidade de moradores

Ranking importância de variáveis com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Sexo	1º	14º	43º	3º	1º
Língua Estrangeira	2º	1º	1º	1º	2º
Renda familiar mensal	3º	2º	2º	2º	4º
Qtde. computadores	4º	3º	3º	4º	9º
Cor/raça	5º	4º	4º	5º	10º
Qtde. freezers	6º	5º	5º	7º	12º
Dependência adm.	7º	17º	6º	6º	7º
Cód. município	8º	9º	7º	12º	6º
Faixa etária	9º	7º	8º	18º	3º
Tipo de escola	10º	21º	15º	10º	14º
Vínculo Sec. Edu	13º	11º	10º	8º	5º
UF escola	15º	8º	12º	11º	8º
TV por assinatura	11º	10º	9º	9º	21º
Ocupação pai	12º	6º	11º	16º	13º

Socioeconômicas

- Confirmam padrões de estudos anteriores
- Novas observações
- Superam variáveis tradicionais
 - Quantidade de banheiros
 - Quantidade de moradores

Escolares

- Cinco
- Relacionadas
 - Localização
 - Gestão

Ranking importância de variáveis escolares com SHAP

Variável	Mat.
Dependência adm.	1º
Cód. município	2º
Tipo de escola	3º
Vínculo Sec. Edu	4º
UF escola	5º
Categ. escola privada	6º
Órgão regional	7º
Emp. privada mant.	8º
Qtde. psicólogos	9º
Região geográfica	10º

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.
Dependência adm.	1º	5º
Cód. município	2º	2º
Tipo de escola	3º	7º
Vínculo Sec. Edu	4º	3º
UF escola	5º	1º
Categ. escola privada	6º	4º
Órgão regional	7º	6º
Emp. privada mant.	8º	8º
Qtde. psicólogos	9º	9º
Região geográfica	10º	
Sala de artes		10º

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.
Dependência adm.	1º	5º	1º
Cód. município	2º	2º	2º
Tipo de escola	3º	7º	5º
Vínculo Sec. Edu	4º	3º	3º
UF escola	5º	1º	4º
Categ. escola privada	6º	4º	6º
Órgão regional	7º	6º	7º
Emp. privada mant.	8º	8º	8º
Qtde. psicólogos	9º	9º	9º
Região geográfica	10º		10º
Sala de artes		10º	

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.
Dependência adm.	1º	5º	1º	1º
Cód. município	2º	2º	2º	5º
Tipo de escola	3º	7º	5º	3º
Vínculo Sec. Edu	4º	3º	3º	2º
UF escola	5º	1º	4º	4º
Categ. escola privada	6º	4º	6º	6º
Órgão regional	7º	6º	7º	7º
Emp. privada mant.	8º	8º	8º	9º
Qtde. psicólogos	9º	9º	9º	10º
Região geográfica	10º		10º	
Mant. sem fins lucr.				8º
Sala de artes		10º		

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Dependência adm.	1º	5º	1º	1º	3º
Cód. município	2º	2º	2º	5º	2º
Tipo de escola	3º	7º	5º	3º	6º
Vínculo Sec. Edu	4º	3º	3º	2º	1º
UF escola	5º	1º	4º	4º	4º
Categ. escola privada	6º	4º	6º	6º	5º
Órgão regional	7º	6º	7º	7º	7º
Emp. privada mant.	8º	8º	8º	9º	8º
Qtde. psicólogos	9º	9º	9º	10º	9º
Região geográfica	10º		10º		
Mant. sem fins lucr.				8º	
Auditório					10º
Sala de artes		10º			

Com 13 variáveis consigo recuperar as 10 mais importantes de cada disciplina

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Dependência adm.	1º	5º	1º	1º	3º
Cód. município	2º	2º	2º	5º	2º
Tipo de escola	3º	7º	5º	3º	6º
Vínculo Sec. Edu	4º	3º	3º	2º	1º
UF escola	5º	1º	4º	4º	4º
Categ. escola privada	6º	4º	6º	6º	5º
Órgão regional	7º	6º	7º	7º	7º
Emp. privada mant.	8º	8º	8º	9º	8º
Qtde. psicólogos	9º	9º	9º	10º	9º
Região geográfica	10º	19º	10º	16º	11º
Mant. sem fins lucr.	13º	13º	13º	8º	15º
Auditório	14º	16º	16º	12º	10º
Sala de artes	21º	10º	11º	17º	43º

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Dependência adm.	1º	5º	1º	1º	3º
Cód. município	2º	2º	2º	5º	2º
Tipo de escola	3º	7º	5º	3º	6º
Vínculo Sec. Edu	4º	3º	3º	2º	1º
UF escola	5º	1º	4º	4º	4º
Categ. escola privada	6º	4º	6º	6º	5º
Órgão regional	7º	6º	7º	7º	7º
Emp. privada mant.	8º	8º	8º	9º	8º
Qtde. psicólogos	9º	9º	9º	10º	9º
Região geográfica	10º	19º	10º	16º	11º
Mant. sem fins lucr.	13º	13º	13º	8º	15º
Auditório	14º	16º	16º	12º	10º
Sala de artes	21º	10º	11º	17º	43º

Maior impacto de variáveis de:

- Localização (3)

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Dependência adm.	1º	5º	1º	1º	3º
Cód. município	2º	2º	2º	5º	2º
Tipo de escola	3º	7º	5º	3º	6º
Vínculo Sec. Edu	4º	3º	3º	2º	1º
UF escola	5º	1º	4º	4º	4º
Categ. escola privada	6º	4º	6º	6º	5º
Órgão regional	7º	6º	7º	7º	7º
Emp. privada mant.	8º	8º	8º	9º	8º
Qtde. psicólogos	9º	9º	9º	10º	9º
Região geográfica	10º	19º	10º	16º	11º
Mant. sem fins lucr.	13º	13º	13º	8º	15º
Auditório	14º	16º	16º	12º	10º
Sala de artes	21º	10º	11º	17º	43º

Maior impacto de variáveis de:

- Localização (3)
- Gestão (7)

Ranking importância de variáveis escolares com SHAP

Variável	Mat.	Ling.	C. Hum.	C. Nat.	Red.
Dependência adm.	1º	5º	1º	1º	3º
Cód. município	2º	2º	2º	5º	2º
Tipo de escola	3º	7º	5º	3º	6º
Vínculo Sec. Edu	4º	3º	3º	2º	1º
UF escola	5º	1º	4º	4º	4º
Categ. escola privada	6º	4º	6º	6º	5º
Órgão regional	7º	6º	7º	7º	7º
Emp. privada mant.	8º	8º	8º	9º	8º
Qtde. psicólogos	9º	9º	9º	10º	9º
Região geográfica	10º	19º	10º	16º	11º
Mant. sem fins lucr.	13º	13º	13º	8º	15º
Auditório	14º	16º	16º	12º	10º
Sala de artes	21º	10º	11º	17º	43º

Maior impacto de variáveis de:

- Localização (3)
- Gestão (7)

Outros fatores


- Suporte profissional
- Cultura/artes

Conclusão: modelagem e importância das variáveis

- **LightGBM** apresentou o melhor desempenho
- Integração ENEM e Censo Escolar ampliou a análise
- Contribuição dos fatores:
 - Socioeconômicos: 65-68%
 - Escolares: 32-35%
 - Disciplinas:
 - Linguagens: menor impacto escolar (32%)
 - Ciências da Natureza: maior impacto escolar (35%)
- Observadas novas variáveis socioeconômicas relevantes, além das tradicionais

Conclusão: fatores **escolares** de maior impacto

- **Localização** e **gestão**: alto impacto na nota final, mas ainda relacionados a fatores econômicos



- **Novas variáveis relevantes**


Cultura



Suporte Profissional



Tecnologia



■ Entre as 10 mais relevantes ■ Após as 10 mais relevantes

Conclusão: fatores econômicos e escolares

- Fator econômico continua sendo determinante no desempenho (Becker, 1993; Adeodato et al., 2014)
- Influência ocorre de forma direta (recursos materiais) e indireta (capital cultural) (Bourdieu e Passeron, 1964, 1970)
- Escolas refletem desigualdades econômicas do país

Intervenções nas escolas

- Investimento em infraestrutura e apoio profissional
- Políticas devem ampliar acesso tecnológico e cultural



Obrigado